





Mayan Scrapping



*Pan Zaldivar, Cristian
Quevedo Zaldivar, Luis Jonathan
Vazques Rodriguez, Diana Carolina*

Web Scraping



- Se analiza el HTML y realizamos tareas específicas

```
from bs4 import BeautifulSoup
from utils.scraping_helpers import get_html_parser, get_date, get_content, get_title, create_csv
```

```
def main ():
    months = ["enero", "febrero", "marzo", "abril", "mayo", "junio", "julio", "agosto", "septiembre", "octubre", "noviembre", "diciembre"];
    url = "https://www.lajornadamaya.mx/k'iintsil/";
    year = "-2023";
    data = [];
```

```
for month in months:
    url_aux = url + month + year
    soup: BeautifulSoup = get_html_parser(url_aux)
    blogs_url= soup.select(".post-headline")
```

- Se construye la URL de cada mes
- Se obtiene el HTML con la página del mes con `get_html_parser(url_aux)`
- Se extrae los elementos con `".post-headline"`



WEB SCRAPING

```
for blog_url in blogs_url:  
    blog_url_href = blog_url.get('href')  
    print(blog_url_href)
```

Se obtiene el enlace del artículo usando
.get('href').

```
blog = get_html_parser(blog_url_href)  
title = get_title(blog);  
date = get_date(blog);  
content = get_content(blog);  
data.append([title, date, content]);
```

- Se extraen título, año y contenido
- Se guarda en la lista data

```
create_csv(data, file_name='data-blog-2023.csv')
```



WEB SCRAPING

```
def get_html_parser(url: str) -> BeautifulSoup:
    data = requests.get(url).text;
    return BeautifulSoup(data, "html5lib")
```

- Descarga el HTML de la página con `requests.get(url).text`

```
def get_title(soup: BeautifulSoup) -> str:
    return soup.find("a", class_="post-headline").get_text()
```

- Encuentra el título de la noticia buscando una etiqueta `<a>` con la clase "post-headline".

```
def get_date(soup: BeautifulSoup) -> str:
    date_p = soup.select(".post-meta p:nth-child(2)")
    return date_p[0].get_text().split("|")[0].strip()
```

- Encuentra la fecha en un párrafo `<p>` dentro de `.post-meta`

PARA EL CONTEDIDO

- Busca los párrafos (<p>) dentro de .single-blog-content.
- Extrae el texto de cada párrafo, eliminando espacios en blanco



```
def get_content(soup: BeautifulSoup) -> str:
    content = soup.select(".single-blog-content > p")

    return "\n".join(
        item.get_text().strip()
        for item in content
        if item.get_text().strip()
        and "En español:" not in item.get_text()
        and "Xak'alutskíinsa'an tumen:" not in item.get_text()
    )
```

```
def create_csv(data: list, file_name: str) -> None:
    df = pd.DataFrame(data, columns=['title', 'date', 'content'])
    df.to_csv('data.csv', index=False, encoding='utf-8')
```